

CommFormer 深度拆解與評估報告

論文: Learning Multi-Agent Communication from a Graph Modeling Perspective 作者: Shengchao Hu, Li Shen, Ya Zhang, Dacheng Tao 單位: SJTU + Shanghai AI Lab + JD Explore Academy + NTU 會議: ICLR 2024 Code: <https://github.com/charleshsc/CommFormer> (亦同 [jd-opensource/CommFormer](#))
報告語言: 繁體中文 (zh-TW) — 技術術語保留英文

1. Overview (論文總覽)

論文資訊

- Title:** Learning Multi-Agent Communication from a Graph Modeling Perspective
- Authors / Affiliation:** Shengchao Hu (SJTU), Li Shen (corresponding, JD Explore), Ya Zhang (SJTU), Dacheng Tao (NTU)
- Venue:** ICLR 2024 (poster)

一句話摘要

CommFormer 把「多 agent 之間誰應該跟誰通訊」直接視為一張可學習的有向圖 (learnable directed graph) · 透過 Gumbel k-hot 連續鬆弛 + bi-level optimization 與 Transformer encoder/decoder 端到端聯合學習通訊拓撲與 policy · 在 bandwidth-constrained 條件下逼近 fully-connected 的上界效能。

研究動機 (Motivation)

作者觀察到三個 communication learning in MARL 長期未解的痛點：

- Pre-defined topology 變異極大**：Figure 1 顯示在 SMAC 1c3s5z、8m_vs_9m 等任務中，用不同隨機 seed 手動指定通訊圖，勝率方差巨大 — 證明「拓撲結構本身」就是顯著影響因子，不應交給人工經驗。
- Full communication 不切實際**：CommNet / TarMAC / MAT 等方法允許所有 agent 互通，但在 wireless 場景中受 bandwidth 與 contention 限制；當 N 變大時 noise 主導 signal，反而傷害合作 (Jiang & Lu, 2018)。
- Dynamic scheduling 太重**：ATOC / IC3Net / ToM2C 在 inference 期動態決定誰跟誰講話，需要額外的 gating / scheduling 模組，bandwidth 浪費且難部署到真實無線通訊上。

三大痛點詳解 (What Each Pain Point Means)

(a) Pre-defined Topology 變異極大 — 手工拓撲的「靠運氣」問題

直白定義：在 communication MARL 中，「誰連誰」就是一張通訊圖 (communication topology)。傳統做法是工程師根據先驗知識 (ring、star、fully-connected、k-nearest 等) 手動指定這張圖，再把它當常數塞進演算法裡。

為什麼是問題？ - Figure 1 的關鍵實驗：同一個 SMAC 任務、同一個演算法，只是換不同隨機 seed 來「隨機抽一張 fixed topology」，最終勝率落差可達 30–60%。這意味著「拓樸選擇」本身就是顯著影響因子。 - 但 MARL paper 普遍只寫「我們採用 fully-connected」或「我們用 k-nearest」，從不分析為什麼這個拓樸最佳 — 結果是 paper 之間的 baseline 比較其實混進了「拓樸運氣」這個 confounder。 - 真實無線網路下根本不存在「自然」的拓樸：5G/6G base station 之間 X2/Xn interface 的可用度受地理位置、回傳容量、政策路由動態影響，沒有一張「對的」靜態圖可抄。

具體後果： - 同一演算法搬到新任務需要重新「猜拓樸」，工程迭代成本高。 - Reproducibility 差 — 論文中 work 的 topology 在你的 setup 可能完全失效。 - 「拓樸是 hyperparameter」這件事被整個 communication MARL 圈集體忽視。

(b) Full Communication 不切實際 — 「全連通」假設的兩大破口

直白定義：「Full / dense communication」指允許所有 N 個 agent 在每一個時間步互相傳遞訊息。

CommNet、TarMAC、MAT 都採此設計，看似最 powerful (資訊上界)。

為什麼是問題？ 1. **Bandwidth 物理限制：**5G/6G NR 基站之間的 X2/Xn interface 有實體頻寬上限；100 個 BS 全互通則控制平面流量是 $O(N^2)$ ，會直接壓垮 transport network。同樣道理也適用於多無人機編隊 (air-to-air link 受功率限制) 與車聯網 (V2V 頻譜稀缺)。 2. **Signal-to-noise 反向 scaling：**當 N 變大，每個 agent 收到的 message vector 經 attention 或 mean-pool 聚合後，實質是「全體的平均」，個別重要訊號被稀釋。 Jiang & Lu (2018) 的實驗顯示， $N > 10$ 時 dense communication 反而比 partial communication 差 — 這是反直覺但已被多次重現的現象。 3. **Contention 與延遲：**wireless MAC 層上多 agent 同時送訊息會碰撞，real-time 部署不可能保證 every agent every step 都能收齊所有人的 message。

具體後果： - MAT 在 SMAC 小 N (5–10 agent) 跑得好，但在 25m, 27m_vs_30m 這種高 N 任務勝率明顯下滑 (Table 1 數字反映此點)。 - 任何「全互通」的 paper 在工業部署評估時都會被打回票 — 因為頻寬假設不成立。 - 學術上的「資訊上界」與工程上的「不可實作」之間有巨大鴻溝。

(c) Dynamic Scheduling 太重 — 「即時排程」的工程災難

直白定義：ATOC、IC3Net、ToM2C 等方法在 inference 期動態決定「這個時間步誰跟誰講話」 — 它們不固定圖，而是訓練一個 scheduler / gating 模組來即時開關通訊邊。

為什麼是問題？ - **Scheduler 自身就要通訊：**要決定「 i 是否該跟 j 講話」，scheduler 通常需要先看到 i 與 j 的部分狀態 — 這變成 chicken-and-egg：要知道誰該講話，自己已經先講了一輪。 - **Bandwidth 浪費在 control plane：**scheduler 的決策訊號 (gating bits) 跟實際資料訊息混搶有限頻寬，相當於要先付一筆「協商費」才能講話。 - **Latency 不可預測：**每個時間步重新計算圖，hardware-level 的 setup / teardown 成本很高 — 5G NR slot 只有 0.5ms，沒空在 slot 內重新建一條 X2 連線。 - **訓練不穩定：**scheduler 是離散決策 (接通 / 不接通)，需要 Gumbel-Softmax 或 REINFORCE 之類的高方差 estimator，常常要靠 reward shaping 才訓得起來。

具體後果： - ATOC / IC3Net 在 paper 上看似 elegant，但實作複雜、reproduce 困難，且幾乎都沒在大規模任務 (>20 agent) 驗證過。 - 對 5G/6G 部署來說，動態 scheduler 違反「control plane 與 data plane 分離」的設計原則 — 工程師看到就頭痛。 - 即使能 train 起來，inference 期的不確定延遲讓 system-level QoS 保證變得困難。

5G / 6G 場景對應 (SCH-MARL final project 的現實意義)

你正在做的 SCH-MARL (5G/6G 多基站異質網路資源分配) 剛好同時被這三個痛點打中： - 痛點 (a)：BS 之間「該不該交換 channel state / load info」沒有顯然的最佳拓樸 — 不同地理部署、不同 traffic pattern

下都不一樣。 - 痛點 (b)：所有 BS 全互通會壓垮 backhaul，且 macro / micro / IoT relay 的異質性讓 mean-pool aggregation 喪失語義。 - 痛點 (c)：3GPP 規範下 X2/Xn interface 是「長連接」，不可能每個 slot 重新排程；scheduler 本身的訊息也要走同一條 backhaul。

因此 CommFormer「離線學一張稀疏靜態圖、上線只用這張圖」的策略剛好命中你的需求——它跟你 final project 的工程約束 (bandwidth-constrained、deployable、低 control overhead) 天然契合，這也是為什麼 CommFormer 是值得拿來做 SCH-MARL backbone 的核心理由。

作者主張：在 inference 前先「離線」搜出一張稀疏靜態圖，比運行時動態調度更實用、更省頻寬。

解決方案概述

- 將通訊架構建模為 directed graph $G = (V, E)$ ， N 個 agent 為 nodes，adjacency matrix $\alpha \in \mathbb{R}^{N \times N}$ 是可學參數。
- 用 k-hot Gumbel-Softmax 把離散邊選擇鬆弛為可微，允許梯度流回 α 。
- 訓練採 bi-level optimization：上層更新 α (用 validation rollout)，下層更新 encoder/decoder 參數 θ, ϕ (用 training rollout)。
- 用 Multi-Agent Transformer (MAT, Wen et al. 2022) 為 backbone——encoder 處理 obs sequence，decoder auto-regressive 產出 action sequence，並將 α 同時作為 attention mask (硬約束) 與 edge embedding (注入結構資訊)。

2. Key Features (核心特色與方法拆解)

2.1 核心方法 Pipeline

階段	元件	作用
Graph 取樣	$\alpha \in \mathbb{R}^{N \times N} \rightarrow$ k-hot Gumbel	為每個 agent 取出 sparsity = S 的 adjacency row e_i
Encoder	Relation-enhanced Transformer	觀察序列 $(o_1, \dots, o_n) \rightarrow$ 表徵 $(\hat{o}_1, \dots, \hat{o}_n)$
Critic head	Encoder 後接 MLP $\rightarrow V_\phi(\hat{o})$	估計 value，用 GAE 算 advantage
Decoder	Auto-regressive Transformer	由 $\hat{o}_{1:n}$ 與已產出 action $a_{0:m-1}$ 預測 $\pi_m(a_m \hat{o}_{1:n}, a_{1:m-1})$
雙重 mask	Adjacency mask + causal ($j < i$) mask	確保只接收連通 agent 的訊息 + 序列更新
Loss	$\mathcal{L} = \mathcal{L}_{\text{Encoder}} + \mathcal{L}_{\text{Decoder}}$	TD value loss + PPO clipped objective
Bi-level update	Eq.(9): $\theta, \phi \leftarrow$ train loss; Eq.(10): $\alpha \leftarrow$ val loss	交替更新內外層

2.2 學習通訊拓樸的數學細節

Adjacency 連續鬆弛 (Eq. 11)：

$$e_i = k_hot (k\text{-arg max } [\text{Softmax}(\alpha_{ij} + g_j), j=1..n])$$

其中 $g_j \sim \text{Gumbel}(0, 1)$ 。直觀理解：- 一般 Gumbel-Softmax 是 one-hot 的可微近似；CommFormer 把它推廣成 **k-hot**（每個 agent 必恰好連 $k = S \cdot N$ 條邊）。- 訓練期 forward 用 hard k-hot，但 backward 用 softmax 的連續梯度（straight-through estimator 風格）。- Inference 期 (Eq. 12) 直接 deterministic top-k： $e_i = k_hot(k\text{-argmax}(\alpha_{ij}))$ ，不再注入 Gumbel noise。

Bi-level Optimization (Eq. 6–8)：

$$\min_{\alpha} \mathcal{L}_{\text{val}}(\theta^*(\alpha), \phi^*(\alpha), \alpha) \quad \text{s.t.} \quad \theta^*, \phi^* = \arg \min_{\theta, \phi} \mathcal{L}_{\text{train}}(\theta, \phi, \alpha), \quad \|\alpha\| \leq S \cdot N^2$$

作者沿用 **DARTS** (Liu et al. 2019) 的 first-order approximation：不解 inner optimization 到收斂，只走一步 SGD 後就用當前 θ, ϕ 估計外層梯度。這是 NAS 圈最常見的近似手段，計算上才可行。

2.3 Relation-Enhanced Attention (Eq. 1–3)

把 vanilla self-attention $s_{ij} = o_i W_q^T W_k o_j$ 改寫為：

$$s_{ij} = (o_i + r_{ij}) W_q^T W_k (o_j + r_{ji})$$

其中 r_{ij} 是從 α 取得的 **edge embedding**（不只是 mask，而是把邊的「身份」直接當 query/key 的偏移）。再施加 hard mask：

$$\bar{s}_{ij} = s_{ij} \cdot [e_{ji} = 1] + (-\infty) \cdot [e_{ji} = 0]$$

這個設計的**精妙之處**在於：mask 只決定「能不能通訊」，edge embedding 進一步表達「邊的語義」（誰指向誰、距離、優先級等）——這是借自 Graph Transformer (Cai & Lam 2020) 與作者自己的 Graph Decision Transformer (Hu et al. 2023)。

2.4 技術新穎性 (Novelty)

元件	是否新穎	借自
把 communication topology 視為 learnable graph	新 (在 MARL communication 領域)	NAS / DARTS 的概念遷移
k-hot Gumbel-Softmax 處理 cardinality 約束	中等新穎	one-hot Gumbel (Jang 2016) 的延伸
Bi-level optimization for α vs θ, ϕ	借用	DARTS (Liu et al. 2019)、NAS 通用框架
Transformer encoder/decoder backbone	借用	MAT (Wen et al. 2022) — 幾乎沿用其架構
Relation-enhanced attention	借用	Graph Decision Transformer (Hu et al. 2023, 同作者)
Auto-regressive sequential update + monotonic improvement	借用	MAT / HAPPO

結論：CommFormer 的真正貢獻是把 MAT 的 fully-connected attention 替換成「**bandwidth-constrained, learned-sparse attention**」。架構創新較少，但問題形式化 (formulation) 與訓練策略 (bi-level + k-hot Gumbel) 是首次在 MARL communication 上系統化提出。

2.5 直觀理解 (Intuition)

可以把 CommFormer 想像成「自動排無線電群組」：- 你有 N 個前線小隊，每隊只能聽 k 個其他隊伍的無線電（頻寬限制）。- 一開始你不知道誰該聽誰，於是給每對隊伍一個「重要性分數」 α_{ij} 。- 在每次任務中（rollout），系統根據分數排出 top-k 收聽清單，執行任務拿到分數（reward）。- 任務結束後，反向傳播更新「重要性分數」— 表現好的連線就強化，表現差的就削弱。- 訓練久了，重要性矩陣穩定，就得到一張「最佳無線電網」— 部署時就用這張靜態圖，不用即時排程，省頻寬又可靠。

2.6 訓練流程偽代碼 (Algorithm 1 簡述)

```
for each training iteration:
    # rollout (用 deterministic top-k graph，與 inference 一致)
    sample  $e_t = k\_hot(k\_argmax(\alpha))$ 
    生成  $\hat{o}_t$  via Encoder with mask & edge_emb
    auto-regressively 生成  $a_t$  via Decoder
    收集  $(o_t, a_t, r_t)$  入 replay buffer

    # learning (用 stochastic Gumbel k-hot，引入梯度)
    sample minibatch
    重新 sample  $e = k\_hot(k\_argmax(\text{softmax}(\alpha + g)))$ 
    forward Encoder + Decoder
    compute  $L\_Encoder$  (TD) +  $L\_Decoder$  (PPO clipped)
    update  $\theta, \phi$  with  $L\_train$  (Eq. 9)
    update  $\alpha$  with  $L\_val$  (Eq. 10)
```

3. Contributions (貢獻分析)

3.1 作者宣稱的貢獻

論文 §1 末尾列出三點：1. 提出將通訊架構視為 graph 並透過 bi-level optimization 同時學習 α 與 θ, ϕ 。2. 在 graph modeling framework 下用 attention 動態分配 message credit，並聲稱享有 **monotonic performance improvement guarantee**。3. 大規模實驗（4 環境、>20 任務）驗證一致超越強 baseline。

3.2 我的獨立評估

貢獻	評價	理由
Bi-level + k-hot Gumbel for graph learning	Substantial	在 MARL communication 上是 first-of-its-kind formulation ; 以 NAS 角度看雖不算大新穎，但跨領域遷移本身有價值
Monotonic improvement guarantee 聲稱	Over-claimed ⚠️	此 guarantee 完全繼承自 MAT (Wen et al. 2022) 的 sequential update — 跟學習通訊圖沒有直接關係。論文沒有針對「動態變化的 α 如何不破壞 monotonicity」給出新證明。這是個 reviewer 紅旗。
Static graph 哲學	Substantial	故意對立於 ATOC/ToM2C 的 dynamic scheduling，提出「pre-inference 學固定拓樸」是 deployable 的視角，對工程落地意義大
大規模實驗	Substantial 但不完美	涵蓋面廣，但見 §4 詳細評論

3.3 對社群的影響

- 學術：把 NAS 的 bi-level 框架引入 MARL communication 是一個範式轉移；後續 ICLR/NeurIPS/AAMAS 應會出現多篇沿著這條路徑的延伸工作（如 dynamic re-search、heterogeneous edge type、multi-modal message）。
- 工業：對 5G/6G 邊緣計算、多無人機協作、自動駕駛車隊有實際參考價值 — Appendix F 已點出 logistics warehouse 的應用場景。
- 限制：因 backbone 完全綁 MAT，沿用其優缺點；對 value-decomposition 派（QMIX, QPLEX）不友善。

4. 實驗設計 (Experimental Design)

4.1 Datasets / Benchmarks

環境	類型	為何選	是否合理
SMAC (StarCraftII Multi-Agent)	離散、hard exploration	cooperative MARL 標配	合理且必要
Predator-Prey (PP)	連續/離散混合、homogeneous	經典 MPE 衍生	合理
Predator-Capture-Prey (PCP)	異質 agent (predator + capturer)	測試 heterogeneous	合理且重要
Google Research Football (GRF) 3v2	稀疏 reward、隨機性高	測試 robustness	合理

缺漏的常用 benchmark：- ❌ MAMuJoCo (連續控制) — HARL/HASAC 標配，CommFormer 完全沒測，導致無法跟 off-policy continuous baseline (HATD3, HASAC) 直接比較。- ❌ Bi-DexHands — 同上。- ❌ 大規模 agent 環境 (如 MAgent, Neural MMO) — 既然主打 scalability，N>20 的測試卻缺席，論文最大的論據之一未驗證。

4.2 Baselines

SMAC 部分 (Table 1 上半) : - Communication-free: MAPPO, HAPPO, QMIX, UPDeT, MAT, FC (fully-connected CommFormer , 作為 upper bound) - 涵蓋面 OK , 但缺 **HASAC** (同年 ICLR 2024) — 雖然時間上可能來不及加 , 但這是同會議直接競爭者 , 應在 camera-ready 補上。

SMAC hard+ 任務 (Table 1 中段) : - QGNN, SMS, TarMAC, NDQ, MAGIC, QMIX - ⚠️ 這部分的 **baseline** 數字直接從 QGNN 論文 (Kortvelesy & Prorok 2022) 抄來 , 非作者實跑 — 紅旗。雖然引用前人實驗在 MARL 圈算常見 (避免重複跑大型實驗) , 但會削弱 fairness。

PP/PCP/GRF (Table 1 下半) : - MAGIC, HetNet, CommNet, IC3Net, TarMAC, GA-Comm - 涵蓋 communication 派 baseline 還算完整。

Cherry-picking 嫌疑 : - HAPPO 在多個 SMAC 任務 (25m, 27m_vs_30m, MMM2, 6h_vs_8z, 3s5z_vs_3s6z) 勝率 0% — 與 PKU-MARL 官方數字落差大。可能 baseline 跑得不夠認真 , 有過度貶低嫌疑。 - ⚠️ 這是讀 Table 1 時最該警覺的點。

4.3 Metrics

- Win rate (SMAC) — 標準
- Success rate / Steps Taken (PP, PCP, GRF) — 強調「最短時間達成」是合理動機
- Average cumulative reward (GRF) — 標準
- ❌ 缺通訊量度量 — 既然主打「省 bandwidth」, 應該有「actual bytes / messages per step」的對比 , 但全文沒有 ; 只用 sparsity $\mathcal{S}$ 間接證明 , 說服力打折。

4.4 Ablations

Sparsity $\mathcal{S}$ ablation (Figure 3) : - 在多個 SMAC 任務測試 $\mathcal{S} \in \{0.2, 0.4, 0.6, 0.8, 1.0\}$ 。 - 結論 : 簡單任務 (1c3s5z) $\mathcal{S} = 0.2$ 即可滿勝 ; 複雜任務 (10m_vs_11m, 27m_vs_30m) 需要 $\mathcal{S} \geq 0.4$ 。 - 這是論文最有價值的 ablation , 給了實際部署選擇 $\mathcal{S}$ 的指引。

Architecture searching ablation (Figure 4) : - 用不同 random seed 生成手動 fixed graph , 與 learned graph 對比。 - 證明 learned > random , 但沒對比 **learned vs heuristic graph** (如 ring, fully-connected, k-nearest) — 這是個明顯 gap。

消融的不足 : - ❌ 沒拆掉 edge embedding r_{ij} 看純 mask 的效果 — 不能確定 edge embedding 到底貢獻多少。 - ❌ 沒拆掉 bi-level (用單層 unified loss 同時更新所有參數) — 不能確定 bi-level 是否真的必要。 - ❌ 沒對比 first-order vs second-order DARTS 近似 — 雖然 NAS 圈有共識用 first-order 即可 , 但對 reviewer 仍是一個合理問號。

4.5 實驗結果解讀

- **Headline 結果** : CommFormer($\mathcal{S} = 0.4$) 在 14 個 SMAC 任務有 11 個達 100% 勝率 , 多數匹敵或超越 FC ($\mathcal{S} = 1$) — 這非常關鍵 , 表示 40% 的邊已能達 100% 邊的效能 , 是論文最 solid 的實驗論據。
- **Marginal gain** : 5m_vs_6m (89.6% vs FC 93.8%)、3s5z_vs_3s6z (87.5% vs FC 100%) — 這兩個是 hard+ 任務 , CommFormer 仍有 4–13% gap , 誠實反映稀疏約束的代價。
- **令人困惑** : MAT 在 25m 上 0.0% — 與 MAT 原論文數字嚴重不符 (原 MAT 在 25m 應有 100%) , 高度懷疑 baseline reproduction 出問題。

4.6 可重現性

-  Code 已開源 (github.com/charleshsc/CommFormer)
-  Hyperparameters 詳列於 Tables 2–4 (PPO epochs、clip、num blocks=1、num heads=1、stacked frames、 $\gamma=0.99$)
-  單層單頭 Transformer (num_blocks=1, num_heads=1) — 作者刻意保持極簡 backbone 以證明 graph learning 的貢獻，但這也意味著效能有相當部分依賴 backbone 設計簡潔，scaling up 是否仍 work 未驗證。
-  訓練成本：未明確報告 wall-clock，但 1 個 head + 1 個 block 的 Transformer 計算成本不大；推測單張 V100/3090 可訓 SMAC 任務。

5. Critical Thinking (深度思辨)

5.1 方法的根本假設

CommFormer 的三個隱藏假設：1. 「最佳通訊圖是靜態的」：論文明確選擇學一張固定圖，但這在許多場景不成立 — agent 角色會切換、任務 phase 會變、地圖是動態的。SMAC 雖然 work，是因為 agent 數量固定且角色分明 (stalkers, zealots)。一旦 agent population 動態 (如 Neural MMO、星海全戰)，靜態圖可能崩壞。2. 「Bandwidth 是 hard constraint，不是 cost」：作者把 S 當成 budget，但實際無線通訊中 bandwidth 是可變 cost (與能源、延遲耦合)。把它建模為 soft penalty 應該更貼近現實，但這會破壞 k-hot 的乾淨形式。3. 「Sequential update + auto-regressive decoder 是 cooperative MARL 的正解」：這完全繼承 MAT，但 MAT 的 sequential update 在 agent 數量大 (>30) 時 inference 延遲是 $O(N)$ — 對即時系統不友善，CommFormer 沒解決這個問題。

5.2 潛在弱點與 Failure Modes

弱點	描述	影響
Static graph 對 dynamic team 失效	訓練時 $N=8$ ，部署時 agent 增減則整個 α 失效	限制工業應用
Bi-level 不穩定	First-order DARTS 在 NAS 圈以 collapse / mode degeneracy 聞名 — CommFormer 沒討論這個風險	訓練可能難複現
k-hot 約束過硬	每個 agent 必恰好連 k 個 (不能有 0 個、也不能 $k+1$) — 真實系統中通訊需求極不均勻 (hub agent vs leaf agent)	限制表達力
Auto-regressive 推理延遲	$O(N)$ sequential decoder forward — 100 個 agent 的時間步無法 real-time	大規模部署瓶頸
Encoder 既是 critic 又是 representation generator	兩個目標耦合可能讓 critic loss 干擾 representation learning	訓練不穩

5.3 隱藏的工程細節 (performance 真正來源 ?)

讀完論文加 Appendix C/D，我懷疑 CommFormer 的效能不只來自 graph learning：1. **Stacked frames=4** 用於 $3s_vs_5z$ — 作者悄悄在某個 task 用了 frame stacking，這是強 boosting，但只此一個任務有，其他沒

有。2. **Hyperparameters per-task tuning** (Table 4 顯示 PPO epochs $\in \{5, 10, 15\}$, clip $\in \{0.05, 0.2\}$) — 每任務調參，這在 cooperative MARL 圈算常規但仍要警覺。3. **MAT 本身就是強 backbone** — 把 MAT 當 baseline 看 Table 1，CommFormer 對 MAT 的提升只有少數任務顯著 (如 3s5z, 25m, 27m_vs_30m, MMM2, 6h_vs_8z)，其他任務兩者打平。也就是說，**CommFormer 真正的 gain 集中在 hard+ 異質單位任務**，這也是它最該主打的賣點。

5.4 與既有工作的關係

既有工作	CommFormer 的差異
MAT (Wen 2022)	同 backbone ; CommFormer = MAT + learnable sparse mask
TarMAC (Das 2019)	TarMAC 是 dense soft attention ; CommFormer 是 hard k-hot mask
ATOC (Jiang 2018) / IC3Net (Singh 2018)	ATOC/IC3Net 用 gating 動態決定通訊 ; CommFormer 是 pre-inference static graph
MAGIC (Niu 2021)	MAGIC 用 hard attention + GAT ; CommFormer 直接學 binary adjacency 而非 attention coefficients
CDC (Pesce & Montana 2023)	CDC 用 diffusion 動態調圖 ; CommFormer 強調 static
TWG-Q (Liu 2022)	TWG-Q 學 temporal weight + GCN ; CommFormer 學 binary graph
DARTS (Liu 2019)	NAS 始祖 ; CommFormer 把 DARTS 的搜尋空間從 op 換成 edge

真正超越了它們嗎？在 SMAC 上是；在 dynamic team / partial observability 嚴重 / agent 數量動態的場景，未必。

5.5 Open Questions

- 1. 學到的 graph 是否真的 interpretable？Figure 5 只展示了 1c3s5z 的搜尋過程，沒有對照「stalkers 應該偏好聽誰」的領域直覺。圖學到的結構是否有物理意義？還是純統計巧合？
- 2. 如果加 noise 在 communication channel 上呢？真實無線通訊有 packet loss，CommFormer 沒測 robustness。
- 3. 能否 zero-shot transfer 到不同 N？論文沒給跨 N 遷移實驗。
- 4. 與 emergent language 結合？message 目前是 raw obs/action，沒有 emergent symbolic communication。

5.6 未來研究方向 (資深 reviewer 視角)

- 1. **Dynamic CommFormer**：把 α 條件化在 task phase 或 agent state 上，搜出一族圖而非一張靜態圖，bridge static vs dynamic 的對立。
- 2. **Heterogeneous edge types**：把 binary adjacency 換成 multi-relational (誰指揮誰、誰共享狀態、誰僅傳警報)，對應現實中多種通訊類型。
- 3. **CommFormer × off-policy (如 HASAC)**：本文 backbone 限定 on-policy PPO，限制 sample efficiency。把 graph learning 接入 SAC 系列是明顯機會 — 這正是使用者 final project 的切入點。
- 4. **Bandwidth-as-cost**：把 hard k-hot 約束改為 soft entropy penalty $\lambda \cdot H(\alpha)$ ，允許 cardinality 自適應 — 這需要重新設計 Gumbel-Softmax 變體。

5. 與 Graph Neural Network 後 message passing 結合：目前 CommFormer 只用 Transformer attention 聚合，可比較 GNN-based aggregation 的差異。

6. 與 HASAC 結合的可行性分析 (SCH-MARL Final Project 專屬)

背景：使用者欲將 CommFormer 的 communication graph 學習機制與 HASAC (HARL ICLR 2024) 結合，應用於 5G/6G 多基站異質網路資源分配。本節分析整合的具體方案、難點與切入點。


6.1 兩者的天然契合與張力

面向	HASAC	CommFormer	契合度
範式	CTDE off-policy actor-critic	CTDE on-policy (PPO 為核心)	⚠ 衝突需橋接
Critic	Centralized Q 函數 $Q_{\psi}(s, a^{1:n})$	Encoder 輸出 $V_{\phi}(\hat{o})$	部分相容
Actor 結構	Per-agent independent π · 配 reparam	Auto-regressive Transformer decoder	衝突需重構
理論保證	MEHAML 模板 $\rightarrow$ monotonic + QRE 收斂	MAT 的 sequential monotonic improvement	兩套不同框架
Heterogeneity	原生支援 (HARL = Heterogeneous-Agent RL)	Transformer 共享參數 · 異質性靠 obs encoding	HASAC 較強
Communication	無原生機制 · 假設 fully observable joint state at critic	內建 sparse graph 學習	CommFormer 補 HASAC 缺口

6.2 整合的三種具體方案

方案 A: CommFormer-as-Communication-Module + HASAC-as-Policy (建議優先)

架構：



- 好處：保留 HASAC 完整 MEHAML 理論 (per-agent independent actor 是其 cornerstone) · CommFormer 只當「通訊預處理層」。
- 訓練：bi-level 仍保留 — 內層更新 (HASAC 的 actor + critic + α 控制)、外層更新通訊參數 α (用 critic loss 或 HASAC objective 的 validation 變體)。

- **理論問題**：MEHAML 的 sequential update 假設每個 agent 看到「之前 agent 已更新後的 policy」— 加入 communication 後，message m_i 也是 policy 的函數，需要重新驗證 drift functional D^i 的 monotonicity 條件是否仍成立。
- **HADF 是切入點**：依你的 HARL notes，可改寫 $D^i(\hat{\pi}^i \| s, \bar{\pi}^{j:m})$ 為 $D^i(\hat{\pi}^i \| s, \bar{\pi}, G_{\text{comm}})$ ，其中 G_{comm} 是 CommFormer 學到的 sparse graph — 這是合法的擴展，因為 graph 在每個 update step 為固定 (k-hot 取樣後 detach)，不破壞 drift functional 的可求和性。

方案 B: HASAC + Graph-Conditioned Critic

架構：保留 HASAC 原生 actor，但 critic $Q_\psi(s, a, G)$ 額外條件化在通訊圖上，actor 之間訊息透過 GNN message passing。
 - **好處**：CommFormer 的 graph 直接成為 critic 的輸入，不改 actor 結構。
 - **缺點**：actor 之間缺乏 explicit communication，浪費 CommFormer 的 graph 資訊。

方案 C: 完整融合 MEHAML + Communication Bi-level

架構：把 CommFormer 的 bi-level 嵌入 MEHAML 模板，提出一個新理論框架（暫稱 **C-MEHAML**）：
 - **內層**：MEHAML drift functional 最小化（更新 actor + critic）
 - **外層**：communication graph α 更新（用 validation MaxEnt objective）
 - 這是 **final project 的最強 selling point**，但需要新的 monotonic improvement proof，難度高。

6.3 哪些 component 可以直接用、哪些要改寫

元件	來源	處理方式
k-hot Gumbel-Softmax	CommFormer Eq. 11	✅ 直接用
Bi-level update schedule	CommFormer Eq. 9–10	✅ 直接用，但外層 loss 改為 HASAC objective 的 val 版
Relation-enhanced attention	CommFormer Eq. 2	✅ 可選用，作為 message aggregator
MAT-style auto-regressive decoder	CommFormer/MAT	❌ 應丟棄 — 與 HASAC 的 per-agent independent actor 衝突，且 sequential decoder 在 SAC 的 reparam trick 下無法保證 monotonic improvement
HASAC Actor (per-agent π_i)	HARL/HASAC	✅ 保留，但 input 加上 message
Centralized Q critic	HASAC	✅ 保留
Auto-tuned α (entropy temperature)	HASAC	✅ 必開
Sequential update + random permutation	HARL	✅ 保留（這是 MEHAML 的 cornerstone）
CommFormer Encoder 作為 critic	CommFormer Eq. 4	❌ 應丟棄 — HASAC 已有自己的 Q critic，雙 critic 會互相干擾
PPO clipped objective	CommFormer Eq. 5	❌ 應丟棄 — HASAC 是 off-policy SAC-style

6.4 HAML / HASPI 是否容許這樣的擴展？

依你的 HARL notes，HAML 的 drift functional 抽象為 $D^i(\hat{\pi}^i \| s, \bar{\pi}^{j_{1:m}})$ ，要求滿足三個性質（non-negative、smooth、bounded difference）。注入 communication graph G 後：- 若 G 在每個 update iteration 內為**固定 random variable**（k-hot 取樣後 detach 梯度），則 drift functional 視 G 為條件，本質上是 $D^i(\hat{\pi}^i \| s, \bar{\pi}^{j_{1:m}}, G)$ — 三個性質**仍然成立**（因為條件化不改變函數的解析性質）。- 若 G 隨 $\hat{\pi}^i$ 變化（因為 actor update 會影響下次 graph 取樣），則需要更小心的論證 — 但 CommFormer 的 bi-level 設計剛好把 α 跟 θ, ϕ 的更新解耦在不同 step，避免這個問題。

結論：CommFormer × HASAC 在理論上是可行的擴展，**HADF (Heterogeneous-Agent Drift Function)** 是合法的切入點，但需要在 final project paper 裡明確寫出條件化版本的 drift functional 並重新驗證 monotonic improvement 條件。

6.5 訓練流程整合策略（建議）

```
Initialize: HASAC actor  $\pi_i$ , critic  $Q_\psi$ , target  $Q_\psi^-$ , comm matrix  $\alpha$ , replay buffer B

for each iteration:
    # ROLLOUT (deterministic graph)
    G = k_hot(k-argmax( $\alpha$ )) # detach
    for each step t:
        for each agent i:
            m_i = CommFormerEncoder(o_{1..n}, G)[i]
            a_i =  $\pi_i(o_i \oplus m_i)$  # SAC reparam sample
            execute a, observe r, s'
            push to B

    # LEARNING (stochastic graph for inner, val rollout for outer)
    sample minibatch from B
    G_train = k_hot(k-argmax(softmax( $\alpha + g$ ))) # Gumbel sample, gradient flows

    # Inner: HASAC update (with random permutation, sequential)
    for i in random_permutation(N):
        update  $Q_\psi$  via TD on (s, a, r, s', G_train)
        update  $\pi_i$  via reparameterized policy gradient (HASAC objective)
        update  $\alpha_i$  (auto-tuned entropy)

    # Outer: Communication graph update (every K_outer iterations)
    if iter % K_outer == 0:
        sample val rollout
        compute L_val (HASAC objective on val rollout)
        update  $\alpha$  via  $\nabla_\alpha L_{val}$  (Eq. 10 of CommFormer)
```

關鍵實作建議：- **Replay buffer 要儲存 G** ：因為 off-policy buffer 中存的 (s, a, r, s') 是過去 α 對應的圖生成的，re-use 時要小心 importance weighting；最簡單做法是每次 graph 變動就清空 buffer 或用 prioritized replay。- **外層更新頻率 K_{outer}** 不要太頻繁（建議 $K_{outer} = 100 \sim 500$ iterations），否則 graph 抖動會破壞 actor 的學習穩定性。這在 DARTS 圈也是常見做法。- **驗證集**：可以用 hold-out env seeds 或 latest rollout 的後半段作為 val。

6.6 SCH-MARL 應用情境的特殊考量

5G/6G 多基站異質網路資源分配的特性： - **異質 agent**：macro BS、micro BS、IoT relay — HASAC 原生支援，CommFormer 的 edge embedding 也能編碼 agent 類型差異。 - **動態用戶分布**：load 隨時間變化，這對 CommFormer 的 static graph 假設構成挑戰 — 建議方案 C 或在 inference 期定期重新搜 graph (小規模 fine-tuning)。 - **嚴格 bandwidth constraint**：CommFormer 的 k-hot 直接對應 X2/Xn interface 的連接限制，應用契合。 - **Stochastic policy 必要性**：用戶分布不確定 → HASAC 的 MaxEnt 是合適選擇；不要退回 deterministic policy (HATD3)。

Final project 可主打三個賣點： 1. 第一個 MaxEnt MARL × Learnable Communication Topology 的整合工作。 2. 理論貢獻：條件化版 MEHAML drift functional 的 monotonic improvement 條件。 3. 應用驗證：5G/6G 資源分配 simulator (如 Sionna RT 或 ns-3 + Open5GS) 下的實證。

7. 給研究者/學習者的 Takeaways

7.1 如果要復現 CommFormer 需注意什麼

- **Backbone** 用單層單頭 Transformer (Table 4 顯示 num_blocks=1, num_heads=1) — 不要無腦堆深。
- **PPO clip** 在 SMAC hard+ 任務調到 0.05 (從預設 0.2 下調)，這是穩定關鍵。
- **Stacked frames=4** 只用於 3s_vs_5z，其他任務 stacked=1。
- 訓練步數差異大：Easy task 5e5 steps，Hard+ 1e7~2e7 steps，對應到 SMAC 慣例。
- **Rollout threads=16, episode length=32, batch_size=3200** — 這些數字直接決定你能多快收斂。
- **bi-level** 用 first-order approximation 即可，不需做 second-order Hessian 估計。

7.2 如果要在這基礎上做研究 (low-hanging fruit)

1. 加 **Heterogeneous Edge Types** (multi-relational graph) — 改寫 α 為 $\alpha \in \mathbb{R}^{N \times N \times R}$ ，R 是邊類型數。
2. 替換 PPO 為 HASAC (如 §6 所述) — 這正是 SCH-MARL final project。
3. **Dynamic Re-search at Inference**：在 deployment 期定期觸發 small-step graph update，bridge static vs dynamic 二分。
4. **Soft cardinality penalty** 取代 hard k-hot，允許 cardinality 自適應 + 加 entropy regularization。
5. **Cross-task graph transfer**：學到的 α 能否 zero-shot 應用到不同 N 的任務？
6. **Robustness ablation**：加 message dropout / Gaussian noise 測試 communication channel 不可靠下的表現。

7.3 學習價值 (對 DL 學生)

概念	學什麼
k-hot Gumbel-Softmax	如何把 cardinality-constrained 離散選擇變可微
Bi-level optimization	NAS 圈最重要的 trick · 在 RL/Meta-Learning 處處可用
Relation-enhanced attention	如何把結構資訊 (邊) 注入 Transformer · 超出純 mask 的層次
DARTS first-order approximation	為什麼可以省略 Hessian 仍 work — 這是 ML 系統設計的工程哲學
CTDE 範式	MARL 的標準訓練/部署策略

7.4 作為 DL final project 的可行性評估

維度	評估
實作難度	中高 — 需要熟悉 PyTorch + Transformer + MARL training loop
計算資源	中 — 1 張 RTX 3090/V100 可訓 SMAC 任務 (一個任務 ~12-48 hr)
創新空間	大 — CommFormer × HASAC 的整合本身就是 publishable 級別的延伸
與使用者背景契合	高 — 涵蓋 GNN (graph learning) 、 RL (HASAC) 、系統設計 (5G/6G 應用)
風險點	bi-level + off-policy 的穩定性需要謹慎調校；可能需要 2-3 週的 sanity check 才能 reproduce CommFormer 原始效能
建議起點	(1) 先在 HARL codebase 跑通 HASAC baseline；(2) 再 fork CommFormer 並只保留 graph learning 模組；(3) 把 HASAC actor/critic 接上

8. 綜合評分 (Overall Assessment)

維度	分數 (1-10)	評論
Novelty (新穎性)	7/10	Bi-level 學 communication graph 是首次系統化提出，但架構大量借用 MAT/DARTS。Formulation 創新 > 技術創新。
Technical Soundness (技術紮實度)	7/10	Bi-level + k-hot Gumbel 設計嚴謹，但 monotonic improvement 聲稱有 over-claim 嫌疑 (不是 graph learning 帶來的，是 MAT 帶來的)。
Experimental Rigor (實驗嚴謹度)	6.5/10	SMAC 涵蓋廣，但缺 MAMuJoCo / Bi-DexHands；HAPPO baseline 數字異常低；缺 edge embedding 與 bi-level 的關鍵 ablation；缺實際 bandwidth metric。
Clarity & Presentation (清晰度)	7.5/10	Method 章節數學形式清楚，Algorithm 1 完整。但 Figure 5 的 visualization 不夠深入解讀；experimental setup 不少細節塞 Appendix。
Potential Impact (潛在影響力)	8/10	把 NAS 思維引入 MARL communication 是範式級貢獻；對工業 5G/edge computing 有直接應用價值；後續會孕育多篇延伸工作。

Overall Recommendation: Accept

評論摘要： CommFormer 在 ICLR 2024 是合格的 accept paper。它解決了一個重要實務問題 (bandwidth-constrained communication learning)，formulation 清楚，實驗有說服力，code 開源。

Accept 的關鍵理由： - Static learnable graph 是個有 deployment 價值的視角，對立於 dynamic scheduling 路線並提出可行替代方案。 - SMAC 上 $S = 0.4$ 即可逼近 FC 上界，這是個 strong empirical evidence。 - 對 cooperative MARL communication 圈是顯著推進。

Reject 的可能理由 (如果嚴格的 reviewer 給)： - Monotonic improvement guarantee 過度聲稱，與本文核心貢獻無關。 - 實驗缺 MAMuJoCo / 大 N 場景；HAPPO baseline 數字可疑。 - 關鍵 ablation 缺失 (edge embedding、bi-level 的必要性)。

我作為 area chair 會給 6 / 8 / 6 / 7 的 reviewer 評分混合，最終 accept as poster — 接近 borderline accept 但 leaning positive。對社群有貢獻但不到 spotlight 等級。

附錄：與 HARL/HASAC 比較表

面向	HARL/HASAC (ICLR 2024)	CommFormer (ICLR 2024)
主貢獻	MaxEnt 框架 + MEHAML 模板 + monotonic improvement 證明	Learnable communication graph + bi-level optimization
範式	Off-policy actor-critic (SAC-style)	On-policy actor-critic (PPO-style)
Communication	無 (CTDE assumes joint state at critic)	Sparse learned graph
理論貢獻	嚴謹 (Joint Soft Policy Decomposition + 4 properties)	較弱 (沿用 MAT)
Heterogeneity	原生支援	透過 obs encoding
Benchmark 廣度	6 個 (SMAC, MAMuJoCo, Bi-DexHands, GRF, MPE, LAG)	4 個 (SMAC, PP, PCP, GRF)
主打優勢	理論完備 + 多 benchmark SOTA	部署友善 + bandwidth-aware
對 final project 角色	Policy backbone	Communication module

兩篇結合的核心價值： HARL 提供理論完備的 stochastic policy 框架，CommFormer 補上原生缺失的 communication topology 學習 — 這正是 SCH-MARL 在 5G/6G 場景需要的兩塊積木。

報告完成於 2026-04-23，基於 CommFormer ICLR 2024 全文 (含 Appendix A–F) 細讀與 HARL/HASAC 記憶筆記交叉分析。