

《Maximum Entropy Heterogeneous-Agent Reinforcement Learning》深度拆解與評估報告

Paper: Liu, Zhong, Hu, Fu, Fu, Chang, Yang, "Maximum Entropy Heterogeneous-Agent Reinforcement Learning", ICLR 2024 (arXiv:2306.10715v6, 2025/03 更新) Code: <https://github.com/PKU-MARL/HARL> Project page: <https://sites.google.com/view/meharl> 整理者觀點：以 ICLR Senior Reviewer + Cooperative MARL Area Chair 雙重視角審讀

1. Overview (論文總覽)

1.1 論文資訊

- 標題：Maximum Entropy Heterogeneous-Agent Reinforcement Learning (縮寫 **MEHARL** 框架 · 旗艦演算法 **HASAC**)
- 作者群：北京大學 (Jiarong Liu, Yifan Zhong, Yaodong Yang) + BIGAI + 雪梨科技大學 (Siyi Hu, Xiaojun Chang) + 騰訊 AI Lab (Haobo Fu, Qiang Fu)
- 發表：ICLR 2024 (Conference Paper)
- 延續脈絡：HARL (Zhong et al., 2023) → HAML (Kuba et al., 2022) → 本文 MEHAML / HASAC

1.2 一句話摘要

把 MaxEnt RL 的「Soft Actor-Critic」嚴謹延伸到 cooperative MARL · 提出 **HASAC** 演算法與其廣義模板 **MEHAML** · 並在理論上首次證明 off-policy actor-critic 在 heterogeneous-agent 情境下能單調改善目標、收斂到 **Quantal Response Equilibrium (QRE)** 。

1.3 研究動機 (Motivation)

作者指出當代 cooperative MARL 三大病徵：

病徵	代表方法	後果
Sample inefficiency	MAPPO / HAPPO / HATRPO (on-policy)	任務複雜度 / agent 數量上升時 sample cost 爆炸
Training instability	HATD3 (off-policy 確定性策略)	hyperparameter 敏感、跨 seed 表現差異大
收斂到 sub-optimal NE	所有最大化標準目標 (Eq. 1) 的方法	早期一旦在某個局部最優附近，所有 unilateral deviation 都會降獎勵 → 確定性卡死

三大病徵詳解 (What Each Pain Point Means)

(a) Sample Inefficiency — 樣本效率低下

直白定義：訓練到「會做事」需要大量的環境互動步數 (environment steps)，費時、費電、費 GPU。

為什麼 on-policy 方法 (MAPPO / HAPPO / HATRPO) 特別嚴重？ - On-policy 的核心約束：**每次 policy 更新後，舊的 trajectory 就作廢**——它是用「上一版 policy」採樣的，再拿來訓練新 policy 會違反 importance sampling 假設。 - 結果就是沒辦法像 off-policy 那樣把資料丟進 replay buffer 重複利用，跑完一個 update 就要重採。 - Multi-agent 設定下，joint action space 是 $\prod_i |\mathcal{A}^i|$ ，要 cover 的探索量隨 agent 數量成倍放大。

具體後果： - MAMuJoCo HumanoidStandup 17x1 等 task 動輒 $1e7-4e7$ 步，單卡 RTX 3090/4090 跑單一 task 需 1-3 天。 - 對學生 final project 「跑得動但很緊」；對真實 5G 部署完全不可行 (基站不能 trial-and-error 一千萬次)。

(b) Training Instability — 訓練不穩定

直白定義：訓練曲線震盪、不同 random seed 結果差異大、hyperparameter 稍微一調就崩。

為什麼 off-policy 確定性策略 (HATD3) 特別嚴重？ - TD3 用 deterministic policy $a = \mu(s)$ 配上 Gaussian exploration noise。 - 確定性 policy **沒有 entropy 抵抗 collapse**——一旦學進某個動作，外加的 noise 不夠強就跳不出來。 - Multi-agent 環境對任一 agent 來說是 non-stationary (其他 agent 也在同時學)，critic 的 bootstrap error 會在 N 個 agent 之間連鎖放大。 - 對 hyperparameter (exploration noise std、target update τ 、target policy smoothing 的 noise clip range) 極度敏感。

具體後果： - 同一個演算法跑 4 個 seed，可能 1 成功 3 失敗 (這就是論文要求 ≥ 4 seed 的原因)。 - Reproduce 困難、deploy 不可靠——你不知道下次 retrain 會 success 還是 disaster。

(c) Sub-optimal NE Convergence — 收斂到次優納許均衡

這是三大病徵中最深、也最特屬於 cooperative MARL 的問題，需要先建立兩個基礎概念：

Q1：什麼是 Nash Equilibrium (NE)？

一個 joint policy $\pi^* = (\pi^{*,1}, \dots, \pi^{*,n})$ 是 NE，當且僅當**沒有任何單一 agent 可以透過「單方面改變自己的策略」(unilateral deviation) 獲得更好回報**。

注意：NE **不一定 globally optimal**——一個 game 可能存在多個 NE，每個的 joint return 都不同。

Q2：什麼是 sub-optimal NE？ - 多個 NE 中 **joint return 不是最高** 的那些。 - 論文 §3.2 的 3x3 矩陣遊戲是經典範例：三個 NE 分別是 (A,A) reward=5、(B,B) reward=10、(C,C) reward=20。 - (A,A) 與 (B,B) 都是 sub-optimal NE；只有 (C,C) 是 Pareto-optimal NE。

為什麼標準 MARL 會穩穩卡進去？ - 標準目標 $\max \mathbb{E}[R]$ + deterministic policy update (e.g., PPO clipped objective)。 - 初始 policy 一旦落在某個 NE 的 basin of attraction 內，policy gradient 會往 **最近的 NE 收斂**——任何 unilateral deviation 都會降低當前 reward。 - 要跳到更好的 NE 必須 **多個 agent 「同時」 偏離原本動作**——但 deterministic policy 永遠不會自發這樣做 (沒有人願意自己先掉獎勵去等別人)。 - 結果：訓練曲線好看、reward 穩定收斂，**但收斂的位置是次優 NE**。

5G / 6G 場景對應 (SCH-MARL final project 的現實意義)：

「所有基站都把功率開到最大」就是一個典型的 sub-optimal NE。任何單一基站單獨降功率，自己服務的 UE 馬上被鄰居壓掉、吞吐量下滑——沒有基站願意先退讓。但若所有基站「同時」適度降功率，干擾下降、整體 throughput 反而上升。標準 MARL 看不到這個協調機會，會穩穩卡在「全力對打」的次優均衡。

HASAC 怎麼跳出？ - Stochastic policy 自帶隨機性 → 多個 agent 同時 隨機偏離原動作是有機率發生的事件 - Max-entropy regularization → 留在 deterministic 動作 (entropy = 0) 會被罰 - 因此 agent 集體有機會「跳躍」到 (C,C) 這種需要協同才到得了的更高 reward NE - 最終收斂到的不再是 NE 而是 **Quantal Response Equilibrium (QRE)**——QRE 自帶 stochasticity，依 Boltzmann 分佈把機率分給 reward 較高的動作，不會純 deterministic

§3.2 用一個 3×3 的 cooperative matrix game (reward 5 / 10 / 20 三個 NE) 證明：當初始 policy 偏向次優 NE (A,A) 時，MAPPO / HAPPO 會精確收斂到確定性的 (A,A)，永遠摸不到 Pareto-optimal (C,C)。這個簡單範例其實就是整篇論文的「動機定錨」。


1.4 解決方案概述

三層遞進：

1. **理論定位 (4.1)**：把 cooperative MARL 表示成 PGM (Fig. 2)，引入 optimality 變數 $\mathbf{O}_t$ ，做 structured variational inference → 自然導出 MaxEnt MARL 目標 (Eq. 2)。
2. **演算法 (4.2)**：提出 **HASPI** (Heterogeneous-Agent Soft Policy Iteration)，核心是 **Joint Soft Policy Decomposition (Prop. 1)**，把 joint MaxEnt update 拆成 n 個 sequential 個體 KL minimization，再具體化為 **HASAC** (深度神經網路版)。
3. **模板 (4.3)**：把 HASPI 抽象化為 **MEHAML** 演算法模板，引入 HADF (drift functional)、neighborhood operator $\mathcal{U}^i$ 、sampling distribution β_π ，任何套這個模板的算法都自動繼承單調改善 + QRE 收斂。HAML 是 MEHAML 在 $\alpha = 0$ 時的特例。

2. Key Features (核心特色與方法拆解)

2.1 核心方法 Pipeline



2.2 數學/演算法核心

(a) MaxEnt MARL 目標 (Eq. 2)

$$J(\pi) = \mathbb{E}_{s_{1:T} \sim \rho_\pi, a_{1:T} \sim \pi} \left[\sum_{t=1}^T \left(r(s_t, a_t) + \alpha \sum_{i=1}^n \mathcal{H}(\pi^i(\cdot|s_t)) \right) \right]$$

- α 是 **temperature** · 控制 reward 與 entropy 的權衡。
- $\alpha \rightarrow 0$ 退化為標準 MARL； α 太大則完全失去獎勵信號。

(b) QRE 的 Boltzmann 表徵 (Thm. 1)

$$\pi_{\text{QRE}}^i(a^i|s) = \frac{\exp(\alpha^{-1} \mathbb{E}_{a^{-i} \sim \pi_{\text{QRE}}^{-i}} Q^{\text{QRE}}(s, a^i, a^{-i}))}{\sum_{b^i \in \mathcal{A}^i} \exp(\alpha^{-1} \mathbb{E}_{a^{-i} \sim \pi_{\text{QRE}}^{-i}} Q^{\text{QRE}}(s, b^i, a^{-i}))}$$

這把 **NE $\rightarrow$ QRE** 的 solution concept 升級具象化：QRE policy 是 soft Q-function 對應的 Boltzmann 分布，自帶 **stochasticity**。當 $\alpha = 0$ 時退化為純 NE。

(c) Joint Soft Policy Decomposition (Prop. 1 · 本文最核心)

對任意 agent permutation $i_{1:n} \in \text{Sym}(n)$ ，逐個 agent 解 KL minimization：

$$\pi_{\text{new}}^{i_m} = \arg \min_{\pi^{i_m}} D_{\text{KL}} \left(\pi^{i_m}(\cdot|s) \parallel \frac{\exp(\alpha^{-1} \mathbb{E} Q_{\pi_{\text{old}}^{i_{1:m}}}(s, a_{\text{new}}^{i_{1:m-1}}, \cdot))}{Z_{\pi_{\text{old}}}(s, a_{\text{new}}^{i_{1:m-1}})} \right)$$

等價於聯合策略對「joint Boltzmann target」的 KL minimization。物理意義：MaxEnt MARL = n 個有條件 MaxEnt single-agent RL 子問題的加總，可序列求解。

(d) HASAC pseudocode (Algo. 2 · Appendix F)

每一輪：1. 從 replay buffer 取一個 minibatch；2. 用 **clipped double Q-learning** 風格計算 critic target $y_t = r + \gamma(\min_{i=1,2} Q_{\text{target}, \theta_i}(s_{t+1}, a_{t+1}) - \alpha \sum_i \log \pi^i(a_{t+1}^i | o_{t+1}^i))$ ；3. 隨機抽 permutation $i_{1:n}$ ，依序更新每個 agent 的 actor (reparam trick + clipped double Q)；4. Polyak 平滑更新 target critic。

對比 vanilla SAC：(i) 多了「逐 agent sequential 更新 + 隨機 permutation」，這是繼承 HAPPO 的 trick；(ii) critic 是 **centralized** (吃 joint state + joint action)，actor 仍 **decentralized**，符合 CTDE。

(e) MEHAML 模板 (Algo. 1 · Def. 2 的 MEHAMO)

$$\mathcal{M}_{D^i, \bar{\pi}^{j_{1:m}}}(\hat{\pi}^i) V_\pi(s) \triangleq \mathbb{E}_{a^{j_{1:m}} \sim \bar{\pi}^{j_{1:m}}, a^i \sim \hat{\pi}^i} [Q_{\pi}^{j_{1:m}, i}(s, a) - \alpha \log \hat{\pi}^i(a^i|s)] - D_\pi^i(\hat{\pi}^i|s, \bar{\pi}^{j_{1:m}})$$

- D^i (HADF) 扮演 **soft constraint** (如 KL penalty)；
- $\mathcal{U}^i$ (neighborhood operator) 扮演 **hard constraint** (如 trust region)；

- 套不同 (D^i, U^i) 即可衍生出新的 MaxEnt MARL 算法，全部自動拿到 Thm. 3 的四項保證：(1) 目標單調改善，(2) value func 收斂到 V^{QRE} ，(3) return 收斂到 J^{QRE} ，(4) limit set 全是 QRE。

2.3 技術新穎性 (Novelty 評估)

元件	是否真正新穎	評論
MaxEnt 目標 + PGM derivation	△ 部分	Single-agent 的 PGM/MaxEnt 框架早已由 Levine (2018) 系統化；本文是把它乾淨地移植到 MARL 並接上 CTDE 的 mean-field 假設 $q(a_t s_t) = \prod_i q^i$
Joint Soft Policy Decomposition (Prop. 1)	✔ 真正新穎	這是讓 sequential update 能在 soft setting 下保留 monotonic improvement 的關鍵，是繼承 HAPPO 的 advantage decomposition lemma 的 soft 版本
HASAC 演算法	△ 增量	工程上是 SAC + HARL framework 的合體；但有 sequential update + random permutation + centralized critic 的整合
MEHAML 模板	✔ 真正新穎	把整個 cooperative MaxEnt MARL 抽象到一個帶 drift/neighborhood 的 mirror learning 模板，未來新算法可以直接「套模板就有理論保證」
無 IGO 假設證明	✔ 重要	對比 FOP (要 IGO 才有保證)，HASAC 在一般合作設定下都成立
QRE 作為 MARL solution concept	△ 不算新	QRE 1995 年就有；但作者把它正式化成 MaxEnt MARL 收斂目標，是一次概念清理

2.4 直觀理解 (Intuition)

比喻：傳統 MAPPO 像一群人在山上找最高峰，但他們約定「除非全體一起動，不然不換位置」。如果一開始大家在小山丘上，任何一個人單獨往外走都會掉下山，全體就永遠不離開小山丘。

HASAC 加入了 entropy 「不安分稅」：留在原地 = 確定性 = 0 entropy = 受罰；只要旁邊還沒探索過的方向有「小機率」往外踏，這個小機率就能 bootstrap 整群人逐步遷移到真正的最高峰。MEHAML 則是這套機制的「通用施工手冊」。

3. Contributions (貢獻分析)

3.1 作者宣稱的貢獻

- 首個 theoretically-justified actor-critic for stochastic policy in cooperative MARL，無 IGO 限制。
- PGM 推導出 MaxEnt MARL 目標 + Joint Soft Policy Decomposition 提案。
- HASAC 演算法 + monotonic improvement / QRE convergence 證明 (Lemma 4.1, 4.2; Thm. 2)。
- MEHAML 統一模板 (Thm. 3 : 4 項性質全保留)。
- 在 6 大 benchmark / 35 task 中 31 個拿 SOTA。

3.2 我的獨立評估

貢獻	評級	我的判斷
PGM → MaxEnt MARL 目標	Substantial	作者誠實標明這是「移植 Levine 2018」，但完整地處理了 multi-agent 情境下的 $q(a_t s_t) = \prod_i q^i$ 假設 + risk-seeking avoidance 的細節
Joint Soft Policy Decomposition	Substantial	是讓整個 sequential update 在 soft 設定下不破壞 monotonic improvement 的數學樞紐；比論文敘述更重要
HASAC 本身	Incremental but solid	工程組合度高，但每個元件 (centralized critic, sequential update, reparam) 都有先例
MEHAML 模板	Substantial	真正 long-term 影響的貢獻 — 提供未來 MARL paper 「快速理論化」的工具
實驗覆蓋	Strong	35 tasks 橫跨連續 / 離散 / hard exploration / 高 agent 數，誠意足

3.3 對社群的影響

- **理論社群**：MEHAML 會被當成新的「default theoretical scaffolding」for MaxEnt MARL，類似 HAML 之於 NE-based MARL 的地位。
- **應用社群**：HARL 框架 (含 HASAC) 已開源，PKU-MARL 是一個有口碑的 lab，HASAC 很可能會變成 new default off-policy MARL baseline，取代 MADDPG / HATD3 在 paper 裡的 baseline 位。
- **跨領域**：對「需要 stochastic policy 的合作場景」(5G/6G 資源分配、多機器人協調、自駕車隊) 特別有吸引力。

4. 實驗設計 (Experimental Design)

4.1 Benchmarks

Benchmark	性質	Tasks	用途
Matrix Game (§3.2)	玩具 / 單狀態 / 3×3	1	證明 MAPPO/HAPPO 必收斂到次優 NE，HASAC 能逃出
Bi-DexHands	連續控制、雙手操作	9	驗證 sample efficiency 與 robustness
MAMuJoCo	連續控制、物理模擬	10	驗證 high-agent-count (17 agents) 情境
SMAC	離散、超難協調	8 (4 hard + 4 super-hard)	驗證 super-hard 任務的 exploration
GRF	離散、稀疏獎勵	2 (RPS, Corner)	驗證 sub-optimal NE 逃離能力
MPE	離散+連續、簡單合作	6	驗證泛化性
LAG	連續、空戰場景	1 (2v2 non-weapon)	驗證新環境的可遷移性

評估：35 tasks 中 HASAC 拿下 31 個最佳。整體合理性：Benchmark coverage 是 Cooperative MARL 領域的黃金組合，沒看到明顯的 cherry-picking 問題。SMAC 與 MAMuJoCo 是 must-have，Bi-DexHands + LAG 增加了多樣性，MPE 補上 simpler baseline 對照。

4.2 Baselines

Baseline	類型	是否合理
MAPPO	On-policy 同步	✓ 必選
HAPPO / HATRPO	On-policy 序列	✓ 必選 (HASAC 的 on-policy 對應)
HATD3	Off-policy 確定性	✓ 必選 (HASAC 的 off-policy 對應)
QMIX	Value-decomposition	✓ 對 SMAC 必選
FOP	MaxEnt MARL (IGO 假設)	✓ 直接競爭對手
SAC / PPO (單 agent)	sanity check	✓ Bi-DexHands 用

Reviewer 紅旗： - 沒有對 MASQL (multi-agent SQL) 做實驗對比，只在 §2 提及。理由 (無理論保證) 勉強過關，但可以補。 - 沒有 MAT / MAPPO+intrinsic reward 等 exploration-augmented baselines——對「逃離次優 NE」這個論點，這些其實是更強的對手。

4.3 評估指標

- 連續控制：episode return (mean $\pm$ std over 4+ seeds)
- 離散 SMAC：median win rate $\pm$ std
- 矩陣遊戲：joint policy 的 entry-wise probability (質化分析 + Table 3 精確計算)

遺漏：作者沒有報告 wall-clock training time 與 sample count to convergence 的完整對照表 (雖然有提) ；對「sample efficiency」這個重點 claim，這應該標準化。

4.4 Ablation Studies (§5.2 + Appendix I)

Ablation	結論	我的評論
Stochastic vs. Deterministic policy (Fig. 4a)	Stochastic 顯著贏	漂亮地把功勞歸給 stochasticity 而非 sequential update
Temperature α scan (Fig. 4b/c, Fig. 5)	中等 α (如 5–10) 最佳；過大失去 exploit、過小退化為 NE	與 SAC 的 α 觀察一致
Auto-tuned α (Appendix H.1)	工程細節，模仿 Haarnoja et al. 2018 的 dual gradient	Essential trick，很多 reproduce 失敗的人會卡在這裡
Sequential update (Appendix I)	隨機 permutation 比固定順序好	與 HAPPO 結論一致

遺漏：沒做「centralized critic vs. decomposed critic」的 ablation——FOP/QMIX 是 decomposed critic，HASAC 是 centralized，把這層拆開能讓貢獻更清楚。

4.5 實驗結果 takeaway (深度解讀)

- **SMAC (Table 1)** : HASAC 在 7/8 map 拿 $\geq 90\%$ 勝率，最強 contrast 是 super-hard 3s5z_vs_3s6z 的 95.0(3.1)% vs. HAPPO 76.2(3.1)% 與 FOP 0.0(0.0)%——**FOP 完全垮掉**正是 IGO 假設破產的證據，這是論文最具說服力的單一數據點。
- **Bi-DexHands** : 所有 on-policy baseline 在 10M steps 內失敗，HATD3 不穩定大幅波動，HASAC 一馬當先——這完美對應作者「stochastic policy $\gg$ deterministic + Gaussian noise」的核心論點。
- **Matrix Game** : Table 3 給出 $\alpha = 10$ 時 (C,C) 機率 0.91 的精確計算 vs. MAPPO/HAPPO 的 (1,0,0)——這是論文最巧妙的展示，因為它把抽象的「逃離次優 NE」具體量化。
- **GRF** : MAPPO/HAPPO 卡在 80% 勝率 (次優 NE)，HASAC 突破——這驗證了在 sparse reward + 大狀態空間下 stochasticity 的價值。

4.6 可重現性

-  公開原始碼 : <https://github.com/PKU-MARL/HARL> (Star 數高，社群採用度好)
-  **HARL framework** : HATD3、HAPPO、HATRPO、MAPPO 都在同一個 codebase，**fairness 問題小**
-  **訓練成本** : MAMuJoCo HumanoidStandup 17x1 / SMAC super-hard 動輒 $1e7-4e7$ steps，單 task 在單卡 (如 RTX 3090 / 4090) 需 1–3 天；對學生 final project 是可接受但偏緊
-  **超參數很多** : 每個 task 的 actor_lr, n_step, batch_size, auto_alpha, alpha_lr 都要單獨設 (Tables 5–10)，重現需要謹慎讀 Appendix H.3

5. Critical Thinking (深度思辨)

5.1 方法的根本假設

1. **CTDE + mean-field policy factorization** : $q(a_t|s_t) = \prod_i q^i(a_t^i|s_t)$ 。這假設 agents 在 evaluation 時不能直接 condition on 其他 agent 的 action (否則就不是 CTDE)。在 **真實通訊受限或 partial observability 嚴重的場景** (你的 5G/6G 跨 BS 協調！) 這假設可能太強。
2. **Soft-policy regularity (Assumption 1)** : 要求所有 $\pi^i(a^i|s) \geq \xi > 0$ 。這在離散 action 是 trivial (用 Gumbel-Softmax) 但在連續 action 暗藏陷阱——靠 reparam trick + bounded log-prob 才實際成立。
3. **Bounded reward + bounded entropy** : 證明 $V^{\max}$ 上界用到。如果 reward 無界 (如 unbounded queue length penalty) 會破壞收斂結論。
4. **Permutation 是隨機抽** : $p(z_{1:n}) > 0$ 對所有 permutation。實作上若做 deterministic permutation，理論不再嚴格適用。

5.2 潛在弱點與限制

1. **計算複雜度沒被認真討論** : sequential update 每 epoch 要過 n 次 actor update (每個 agent 一次 mini-epochs)，當 n 很大 (如 17 agents) 時 wall-clock 顯著拉長；論文沒給完整 timing table。
2. **Centralized critic 的 scalability** : critic 吃 joint state-action $|S| \times \prod_i |A^i|$ ，在 agent 數量更多時 (> 50) 會爆。這是所有 CTDE 方法的通病但作者沒提。

- 3. Entropy 等權重假設：Eq. 2 用同一個 α 對所有 agent。對 heterogeneous agents (不同 action space scale) 這顯然次優——應該每個 agent 一個 α^i 。論文 Appendix H.1 雖有 auto-tuning 但仍是全域。
- 4. QRE 的「品質」沒保證：HASAC 收斂到 某個 QRE，但不保證收斂到 higher-reward QRE。作者用實驗結果證明它「實務上」較好，但這仍是 empirical claim 而非定理。
- 5. Discrete action 全靠 Gumbel-Softmax bridge：理論是為連續策略設計的；離散是用 GS 補強，這引入 bias 與 temperature 偏差。
- 6. 與 communication-based MARL 沒有明確結合點：HASAC 假設無顯式通訊，但你的 final project 想結合 CommFormer，MEHAML 模板是否相容於 learned communication graph 並無正式分析——這既是限制，也是研究機會。

5.3 隱藏的工程細節 (這些是 reproduce 的關鍵)

- Clipped double Q + minimum for critic target (沿用 SAC 標準)
- target entropy = $-\dim(\mathcal{A}^i)$ for auto-tune (標準 trick)
- Gumbel-Softmax for discrete actions with temperature 退火 (連 §5 都只一句帶過)
- Polyak coefficient $\tau = 0.005$ (極關鍵但容易被忽視)
- Sequential update + random permutation 不是「nice to have」，是理論成立的 cornerstone
- Train interval / update per train：MAMuJoCo 用 50:1，Bi-DexHands 用 0.2:1，這對 sample efficiency 影響極大

5.4 與既有工作的關係

方法	與 HASAC 關係
SAC (Haarnoja 2018)	HASAC 的單 agent 對應；HASAC = SAC + sequential heterogeneous update + centralized Q
HAPPO/HATRPO (Kuba 2022)	HASAC 的 on-policy 對應；HASAC = HAPPO + soft objective + off-policy
HARL (Zhong 2023)	HASAC 是 HARL framework 內的 off-policy 新成員；本論文承擔了「HARL 的 SAC 化」
HAML (Kuba 2022)	MEHAML 在 $\alpha = 0$ 時退化為 HAML —— 完美的理論泛化
FOP (Zhang 2021)	直接競爭對手；HASAC 在 無 IGO 假設 上贏
MASQL (Wei 2018)	同樣 MaxEnt MARL，但無理論保證；HASAC 補上理論
MACPF (Wang 2023)	用 imitation learning 從 joint policy distill 出 decentralized policy；HASAC 直接學 decentralized

真的超越了它們嗎？在 cooperative MaxEnt MARL 這個小 niche 內 — 是的，HASAC 是當前 SOTA。但若放寬到「multi-agent exploration」整體，與 communication-based methods (CommFormer, MAT)、curiosity-based methods 還沒有正面對決。

5.5 Open Questions (論文沒回答但重要)

- 1. HASAC 在 multi-agent partial observability 下還成立嗎？ Markov game 假設 full observability，但實務 (如 5G BS) 幾乎都是 partial。
- 2. 大型異質性 (如 $\dim(\mathcal{A}^i)$ 差異 100 倍) 的 α 該如何設？ 全域 α 對小 action space 太強、對大 action space 太弱。
- 3. 能否與 learned communication (CommFormer 那類) 結合？ Centralized critic 與 learned graph 之間的接口怎麼設計？
- 4. Sample complexity 的理論 bound 是什麼？ 論文只證收斂，沒給 PAC-style sample complexity bound。
- 5. 若有 non-stationary opponents 或對抗性 agents，QRE 還能用嗎？ 純合作設定外失效。

5.6 未來研究方向 (4 個有前景的延伸)

- 1. MEHAML $\times$ Learned Communication Graph (你們 SCH-MARL 的 sweet spot)：把 CommFormer 學到的 sparse communication graph 當作 HADF 的條件變數 $D^i(\hat{\pi}^i | s, \pi^{j:m}, G_{\text{comm}})$ ，理論上可在通訊圖上重新定義 neighborhood operator $\mathcal{U}^i$ ，獲得「隨通訊拓撲收斂的 QRE」。
- 2. Per-agent adaptive temperature α^i ：對 heterogeneous action space 的 agents 個別 auto-tune，可顯著改善樣本效率。
- 3. Hierarchical MEHAML：上層做 macro action 的 MaxEnt 選擇、下層做 primitive control 的 MaxEnt 執行；對 5G/6G 跨時間尺度資源分配特別合適 (slot-level vs frame-level)。
- 4. Offline MEHARL：把 conservative Q learning (CQL) 與 HASAC 結合，做 offline cooperative MARL。商業價值高 (電信 operator 不能線上探索)。

6. 給研究者/學習者的 Takeaways

6.1 復現 (Reproduce) 注意事項

項目	推薦設定
框架	直接 fork PKU-MARL/HARL repo，不要從零寫
Random seeds	至少 4 seeds (論文標準)；少於這個數一律不可信
連續 action	用 reparam trick + Tanh squashing；勿用直接採樣
離散 action	用 Gumbel-Softmax，temperature 退火 (從 1.0 到 0.1)
Auto-alpha	強烈建議開啟，target_entropy = $-\dim(\mathcal{A}^i)$
Polyak	$\tau = 0.005$ (不要動)
雙 critic	必須用 clipped double Q (SAC 標準)
Replay buffer	1e6 (與 HATD3 一致，避免 unfair)
Permutation	每個 update step 隨機抽新的，不要固定

6.2 在此基礎上的研究低垂果實 (low-hanging fruit)

- 1. Per-agent α^i auto-tuning : 3 行程式碼改動 · 對 heterogeneous setup 立刻有 gain 。
- 2. Prioritized replay 加入 HASAC : 論文用普通 uniform sampling · PER 是 free lunch 。
- 3. N-step return 已有但 task-dependent ; 做更系統的 ablation (n=1,3,5,10,20) 能寫成短 paper 。
- 4. 不同 HADF (KL vs. Wasserstein vs. Jensen-Shannon) 對應不同 trust region ; MEHAML 模板都自動成立 。
- 5. HASAC + Categorical Distributional Critic (C51 / QR-DQN 風格) : 把 distributional RL 的 robustness 加進來 。

6.3 學習價值

對 DL 學生來說，這篇論文最值得學的概念：

- Control as Inference : 理解 PGM 視角下 RL = variational inference 的「同義轉換」；這是現代 RL 一切「軟化」(soft) 方法的根基 。
- Mirror Learning 框架 : drift functional + neighborhood operator 的雙約束組合，是現代 trust region 方法的優雅抽象 。
- Sequential Update 的理論作用 : 理解為何 HAPPO 只要序列更新就能保證 monotonic improvement (Multi-Agent Advantage Decomposition Lemma) 。
- 如何把單 agent 理論「升級」到 multi-agent : 本論文是教科書級別的範例 。
- Reparam trick + Auto-tuning α + Clipped Double Q : SAC 系演算法的「三件套」 。

6.4 作為 final project 的可行性評估 (針對洪翊婕的 SCH-MARL 構想)

維度	評估
實作難度	★★★★ 中 — HARL repo 已成熟 · HASAC 直接可跑 ; CommFormer 也開源 ; 但兩者整合是新工程
計算資源	★★★★ 中高 — 完整 6 benchmark 跑不了 · 建議只做 MAMuJoCo (3 tasks) + 一個自製 5G/6G 環境 ; 單卡 RTX 3090 可行
創新空間	★★★★★★ 高 — MEHAML 模板 × CommFormer 的 learned graph 整合目前無公開工作 ; 切入「MEHAML 在 communication-aware 場景的擴展」非常合時
理論深度	★★★★★ 高 — 可寫進 proposal/poster 的 theory section (HADF 、 QRE 、 MaxEnt MARL) 一次到位
與課程契合度	★★★★★★ 高 — ICLR 2024 、開源、可實作、有理論深度 · 完全符合 rules.txt

建議的 final project 切入路徑：1. Phase 1 (基線) : 在自製 5G/6G 多 BS 資源分配 env 上跑 vanilla HASAC ; 2. Phase 2 (接 CommFormer) : 把 CommFormer 學到的 sparse comm graph $\mathcal{G}$ 作為 HASAC 的 critic input (concat to state) ; 3. Phase 3 (理論升級) : 定義 $D^i(\hat{\pi}^i | \mathbf{s}, \bar{\pi}, \mathcal{G})$ 把 graph 結構納入 drift functional · 宣稱「graph-conditioned MEHAML」；4. Phase 4 (評估) : 對比 (i) HASAC, (ii) HASAC + CommFormer raw, (iii) graph-conditioned MEHAML 在 sample efficiency / final reward / scalability 。

7. 綜合評分 (Overall Assessment)

評估項目	分數	評論
Novelty (新穎性)	8 / 10	Joint Soft Policy Decomposition 與 MEHAML 模板是真實貢獻；HASAC 本身偏組合式
Technical Soundness (技術紮實度)	9 / 10	證明完整、邏輯嚴謹；Appendix 證明過程教科書級別
Experimental Rigor (實驗嚴謹度)	8 / 10	Benchmark 廣度與 baseline 選擇一流；缺 timing table 與 wall-clock 比較；少數 ablation (centralized vs. decomposed critic) 沒做
Clarity & Presentation (清晰度)	8 / 10	主文敘事清楚；§4 的數學記號 (permutation 上下標) 密度高，初讀不友善；Appendix B 的精確計算非常加分
Potential Impact (潛在影響力)	9 / 10	MEHAML 會成為 cooperative MaxEnt MARL 的標準模板；HASAC 會成為新 baseline

Overall Recommendation : Accept (Strong Accept 邊緣)

評論摘要：

這是一篇罕見地「理論完整 + 工程紮實 + 實驗充分」三位一體的 cooperative MARL 論文。它把 single-agent SAC 的 MaxEnt 框架嚴謹地搬到 heterogeneous-agent 設定下，**第一次在無 IGO 假設下證明 actor-critic 的 monotonic improvement 與 QRE 收斂**，並提供 MEHAML 這個「未來 algorithm designer 可以直接套用的模板」。

主要扣分點是：(i) MEHAML 雖然抽象優雅，但本文只用了 KL drift + 平凡 neighborhood，沒有實證 MEHAML 模板本身的「衍生新算法」價值；(ii) 計算成本與 wall-clock 對比缺失；(iii) Discrete action 的 Gumbel-Softmax 處理理論上是 hack。

但瑕不掩瑜，論文在 ICLR 2024 的位置完全合理，預期會在未來 2–3 年成為 cooperative MARL 的標準引用之一。對洪翊婕的 SCH-MARL final project 來說，這是一個極佳的理論基底——MEHAML 模板給了你一個「可被擴展且自動有理論保證」的腳手架，與 CommFormer 的 communication graph 結合具有真實的學術新意。

附錄 A：可直接寫入「研究動機」段落的素材

在 cooperative multi-agent reinforcement learning (MARL) 中，現有的 state-of-the-art 方法 (如 MAPPO、HAPPO) 面臨三大瓶頸：(1) 樣本複雜度高、(2) 訓練不穩定、以及 (3) 容易收斂到次優 Nash Equilibrium (NE)。Liu et al. (ICLR 2024) 透過一個 3×3 的合作矩陣遊戲嚴謹地證明，當 agents 初始策略偏向次優 NE 時，最大化標準目標的方法將無可避免地收斂到該次優解，因為任何單方偏移都會降低聯合獎勵。為突破此限制，作者提出 Maximum Entropy Heterogeneous-Agent Reinforcement Learning (MEHARL) 框架，**首次在無 Individual-Global-Optimal (IGO) 假設的情況下**，建立 cooperative MARL 中學習隨機 (stochastic) 策略的理論基礎。其核心演算法 HASAC 與廣義模板 MEHAML 不僅證明了單調改善與 Quantal Response Equilibrium (QRE) 收斂性，更在 35 個 benchmark 任務中取得 31 項 SOTA。

附錄 B：可直接寫入「研究方法」段落的素材

我們以 HASAC (Liu et al., 2024) 為核心理論基礎構建 SCH-MARL 框架。HASAC 透過將 cooperative MARL 嵌入機率圖模型 (PGM) 並進行 structured variational inference，自然導出 maximum entropy MARL 目標 $J(\pi) = \mathbb{E}[\sum_t (r(s_t, a_t) + \alpha \sum_i \mathcal{H}(\pi^i(\cdot|s_t)))]$ ，其中 α 為調節 reward 與 entropy 權衡的溫度係數。HASAC 的核心是 Joint Soft Policy Decomposition 命題 (Liu et al., 2024 Prop. 1)，證明 joint MaxEnt update 可分解為 n 個 sequential 個體 KL minimization，從而保證單調改善與 QRE 收斂。在此基礎上，本研究進一步整合 CommFormer (ICLR 2024) 學習到的稀疏通訊圖 G_{comm} ，將其納入 MEHAML 模板的 heterogeneous-agent drift functional $D^i(\hat{\pi}^i|s, \bar{\pi}^{j_{1:m}}, G_{\text{comm}})$ 中，使每個 agent 的策略改善約束自動隨通訊拓撲調整。此設計理論上保留了 MEHAML 的 monotonic improvement 與 QRE 收斂保證 (Liu et al., 2024 Thm. 3)，同時讓 communication 結構成為 trust region 設計的內生變數，特別適用於 5G/6G 多基站異質網路資源分配場景。

整理完成日期：2026-04-23